Politechnika Śląska
Wydział Informatyki, Elektroniki i Informatyki

Podstawy Programowania Komputerów

Kompresja metodą Huffmana

autor	Jan Naklicki
prowadzący	dr inż. Bożena Wieczorek
rok akademicki	2021/2022
kierunek	informatyka
rodzaj studiów	SSI
semestr	1
sekcja	13
termin oddania sprawozdania	2022-01-30

1 Treść zadania

Napisać program do kompresji plików metoda Huffmana. Program uruchamiany jest z linii poleceń z wykorzystaniem następujących przełączników:

- `-i` plik wejściowy
- `-o` plik wyjściowy
- `-t` tryb: k –kompresja, d –dekompresja
- `-s` plik ze słownikiem (tworzonym w czasie kompresji, używanym w czasie dekompresji).

2 Analiza zadania

Zagadnienie przedstawia problem kompresji danych zapisanych w pliku, oraz późniejszej dekompresji.

2.1 Struktury danych

W programie wykorzystano drzewo binarne, na podstawie którego wygenerowania słów kodowych (ciągów bitowych). Oprócz drzewa do przechowywania danych użyto również wektory, mapy, oraz pary.

2.2 Algorytmy

1. Określ prawdopodobieństwo (lub częstość występowania) dla każdego symbolu ze zbioru S.

2. Utwórz listę drzew binarnych, które w węzłach przechowują pary: symbol, prawdopodobieństwo. Na początku drzewa składają się wyłącznie z korzenia.

3. Dopóki na liście jest więcej niż jedno drzewo, powtarzaj:

   3.1 Usuń z listy dwa drzewa o najmniejszym prawdopodobieństwie zapisanym w korzeniu.

   3.2 Wstaw nowe drzewo, w którego korzeniu jest suma prawdopodobieństw usuniętych drzew, natomiast one same stają się jego lewym i prawym poddrzewem. Korzeń drzewa nie przechowuje symbolu.

Drzewo, które pozostanie na liście, jest nazywane drzewem Huffmana – prawdopodobieństwo zapisane w korzeniu jest równe 1, natomiast w liściach drzewa zapisane są symbole.

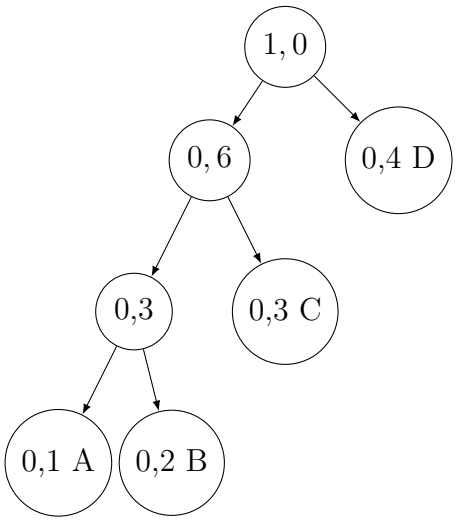

Rysunek 1: Przykład drzewa binarnego przechowującego znaki i ich prawdopodobieństwo.

Algorytm Huffmana jest algorytmem niedeterministycznym, ponieważ nie określa, w jakiej kolejności wybierać drzewa z listy, jeśli mają takie samo prawdopodobieństwo. Nie jest również określone, które z usuwanych drzew ma stać się lewym bądź prawym poddrzewem. Jednak bez względu na przyjęte rozwiązanie średnia długość kodu pozostaje taka sama.

Na podstawie drzewa Huffmana tworzone są słowa kodowe; algorytm jest następujący:

1. Każdej lewej krawędzi drzewa przypisz 0, prawej 1 (można oczywiście odwrotnie).
2. Przechodź w głąb drzewa od korzenia do każdego liścia (symbolu):
   - 2.1 Jeśli skręcasz w prawo, dopisz do kodu bit o wartości 1.
   - 2.2 Jeśli skręcasz w lewo, dopisz do kodu bit o wartości 0.

Długość słowa kodowego jest równa głębokości symbolu w drzewie, wartość binarna zależy od jego położenia w drzewie. [1]

3 Specyfikacja zewnętrzna

Program jest uruchamiany z linii poleceń. Przy kompresji należy przekazać do programu nazwy pliku: wejściowego używając odpowiedniego prze-

[1] `https://pl.wikipedia.org/wiki/Kodowanie_Huffmana`

łącznika (`-i` dla pliku wejściowego), np.

```
huffman-coding -t k -i dane -dane_c
huffman-coding -t d -i dane_c -s dane_s -o dane_d
```

Uruchomienie programu z nieprawidłowymi parametrami powoduje wyświetlenie komunikatu

```
================================================================================
Use correct format
For compressing data use:
huffman-coding -t k -i input_filename -o output_filename
For decompressing data use:
huffman-coding -t d -i input_filename -s dictionary_filename -o output_filename
================================================================================
```

4 Specyfikacja wewnętrzna

4.1 Ogólna struktura programu

W funkcji głównej wywołana jest funkcja validate_input_arguments . Funkcja ta sprawdza, czy program został wywołany w prawidłowy sposób. Gdy program nie został wywołany prawidłowo, zostaje wypisany stosowny komunikat i program się kończy. Następnie wywoływana jest funkcja "setPathByFlag ". Funkcja ta na podstawie odpowiednich flag ustawia nazwy plików wejściowych, oraz wyjściowych. Następnie zależnie od wybranego trybu wykonywane są funkcje: HuffmanEncode, lub HuffmanDecode.

Funkcja HuffmanEncode, zawiera w sobie funkcje pomocnicze, które otwierają plik wejściowy, wczytują tekst z pliku, obliczają prawdopodobieństwa i umieszcza tak przygotowane dane w drzewie binarnym. Następnie na podstawie drzewa tworzony jest słownik. Słownik zapisywany jest do pliku, aby w przyszłości móc odkodować dane. Słownik używamy, żeby zakodować nasz plik wejściowy, każdą literę zamieniamy na odpowiadający jej kod Huffmana. Tak powstaje string zawierający zera i jedynki. Ten ciąg znaków wypisujemy do pliku binarnego.

Funkcja HuffmanDecode, zawiera w sobie dwie pomocnicze funkcje load_dic_file , która wczytuje słownik stworzony przy kompresowaniu. Druga funkcja pomocnicza to decode_from_binary_to_text . Na podstawie wczytanego słownika dekoduje ona plik binarny.

4.2 Szczegółowy opis typów i funkcji

Szczegółowy opis typów i funkcji zawarty jest w załączniku.

5 Testowanie

Program został przetestowany na różnego rodzaju plikach. Plik. Maksymalna rozmiar pliku ograniczony jest przez możliwości sprzętu użytkownika (RAM). Maksymalna wielkość pliku, dla której udało się poprawnie uruchomić program, to 1 GB. Większe pliki wejściowe przy kompresji/dekompresji zajmują dużą ilość czasu.

6 Uzyskane wyniki

Kompresja plików utrzymuje się na poziomie około 50%. Program został przetestowany na plikach o wielkości od 4 kb po 1 GB.

7 Wnioski

Program do kompresowania plików okazał się być troszkę bardziej skomplikowany niż się spodziewałem. Wszystkie etapy od obliczania prawdopodobieństwa po tworzenie drzewa okazało się nie być zbyt wymagające, jednak zapisywanie do plików binarnych, było jedną z mniej przyjemnych rzeczy w moim życiu. Jednak jak już raz udało się to zrobić, rzeczy zaczęły dobrze działać.

Poziom kompresji jest na naprawdę przyzwoitym poziome, jednak czasowo dekompresja ma jeszcze sporo pole do rozwoju. W najbliższym czasie zamierzam naprawić ten problem. W planach jest rozdzielenie wczytywania danych z pliku od ich modyfikacji.

Dla pewnych danych program wykonywał się poprawnie na niektórych komputerach, podczas gdy na innych maszynach generował niepoprawne wyniki. Było to spowodowane, różnym sposobem zapisywania znaków w plikach.

Dodatek
Szczegółowy opis typów i funkcji

Huffman coding

Generated by Doxygen 1.9.3

Chapter 1

Class Index

1.1 Class List

Here are the classes, structs, unions and interfaces with brief descriptions:

Chapter 2

File Index

2.1 File List

Here is a list of all files with brief descriptions:

Chapter 3

Class Documentation

3.1 WezelDrzewa Struct Reference

Struktura używana przy tworzeniu drzewa, przechowuje znak oraz prawdopodobieństwo jego wystąpienia w tekście.

`#include <Helpers.h>`

Public Attributes

- struct WezelDrzewa * parent = NULL
  rodzic węzła
- struct WezelDrzewa * left = NULL
  lewe dziecko
- struct WezelDrzewa * right = NULL
  prawe dziecko
- string ch
  znak
- double probability = NULL

3.1.1 Detailed Description

Struktura używana przy tworzeniu drzewa, przechowuje znak oraz prawdopodobieństwo jego wystąpienia w tekście.

Definition at line 23 of file Helpers.h.

3.1.2 Member Data Documentation

3.1.2.1 ch

```
string WezelDrzewa::ch
```

znak

Definition at line 44 of file Helpers.h.

3.1.2.2 left

```
struct WezelDrzewa* WezelDrzewa::left = NULL
```

lewe dziecko

Definition at line 34 of file Helpers.h.

3.1.2.3 parent

```
struct WezelDrzewa* WezelDrzewa::parent = NULL
```

rodzic węzła

Definition at line 29 of file Helpers.h.

3.1.2.4 probability

```
double WezelDrzewa::probability = NULL
```

Definition at line 45 of file Helpers.h.

3.1.2.5 right

```
struct WezelDrzewa* WezelDrzewa::right = NULL
```

prawe dziecko

Definition at line 39 of file Helpers.h.

The documentation for this struct was generated from the following file:

- Helpers.h

Chapter 4

File Documentation

4.1 Helpers.cpp File Reference

```
#include "Helpers.h"
#include <iostream>
#include <vector>
#include <map>
#include <utility>
#include <fstream>
#include <bitset>
#include <cstdlib>
#include <string>
#include <algorithm>
```

Functions

- int validate_input_arguments (int argc, vector< string > &arg)
- void setPathByFlag (string &flag, string &path, string &input_path, string &output_path, string &dic_path, string &mode)
- int binary_to_decimal (string &in)
- string decimal_to_binary (int in)
- pair< string, char > split_string (string napis)
- bool compare_by_prob (const WezelDrzewa &a, const WezelDrzewa &b)
- map< char, double > calculate_probability (string inputname)
- void create_dictionary (WezelDrzewa *tree, map< char, string > &dictionary, string prevstring)
- template<typename K , typename V >
  void output_dictionary (map< K, V > const &m, string dicfile, int zeros_added)
- WezelDrzewa create_tree (map< char, double > chars_with_prob)
- pair< string, int > coded_message (map< char, string > dictionary, string inputfile)
- void output_to_binary (string huffman_coded_string, string outputfile)
- pair< map< string, char >, int > load_dic_file (string dicFile)
- void decode_from_binary_to_text (map< string, char > decoDic, int number_of_zeros_to_remove, string inputname, string outputname)
- void HuffmanEncode (string inputname, string outputname, string dicfile)
- void HuffmanDecode (string inputname, string outputname, string dictionary)

Variables

- map< char, string > dictionary

4.1.1 Function Documentation

4.1.1.1 binary_to_decimal()

```
int binary_to_decimal (
            string & in )
```

Funkcja przyjmuje oktet, który zamienia z wartości binarnej na wartość dziesiętną.

Parameters

in	8 bitów zapisane jako string

Returns

int

Definition at line 62 of file Helpers.cpp.

4.1.1.2 calculate_probability()

```
map< char, double > calculate_probability (
            string inputname )
```

Funkcja zapisuje wystąpienia znaków do mapy, aby na końcu podzielić ilość wystąpień znaku przez ilość wszystkich znaków w tekście. Otrzymujemy w ten sposób prawdopodobieństwo wystąpienia znaku.

Parameters

filename	nazwa pliku, z którego chcemy wczytać dane

Returns

map<char, double> mapa zawierająca znaki z prawdopodobieństwem ich wysąpienia

Definition at line 119 of file Helpers.cpp.

4.1.1.3 coded_message()

```
pair< string, int > coded_message (
            map< char, string > dictionary,
            string inputfile )
```

Funkcja koduje dane z pliku wejściowego używając słownika stworzonego przez create_dictionary(). Po zakodowaniu wszystkich znaków sprawdza czy ilość zer i jedynek jest podzielna przez 8. Jeżeli nie to doklejamy odpowiednią ilość zer na koniec kodu.

Parameters

dictionary	słownik utworzony przez create_dictionary()
filename	nazwa pliku

Returns

pair<string, int> para zawierająca zakodowany tekst oraz ilość zer dodanych do ostatniego oktetu

Definition at line 207 of file Helpers.cpp.

4.1.1.4 compare_by_prob()

```
bool compare_by_prob (
            const WezelDrzewa & a,
            const WezelDrzewa & b )
```

Funkcja pomagająca przy sortoaniu węzłów drzewa znajdujących się w wektorze porównując prawdopodobieństwo.

Parameters

a	pierwsz węzeł drzewa
b	drgi węzeł drzewa

Returns

true zwraca prawdę jeżeli prawdopodobieństwo zawarte w węźle a jest większe

false

See also

WezelDrzewa

Definition at line 114 of file Helpers.cpp.

4.1.1.5 create_dictionary()

```
void create_dictionary (
            WezelDrzewa * tree,
            map< char, string > & dictionary,
            string prevstring )
```

Struktura WezelDrzewa jest używana do tworzenia drzewa binarnego. WezelDrzewa oprócz standardowych wartości, zawiera również wartość ch oraz probability, które kolejno oznaczają znak, oraz jego prawdopodobieństwo wystąpienia w tekście. Funkcja reukrencyjnie przechodzi po drzewie tworząc kody huffmana dla poszczególnych znaków. Gdy nie ma możliwości przejścia do kolejnych potomków, utworzony kod(w zapisie binarnym) zostaje dodany jako element mapy, wraz ze znakiem, dla którego kod utworzono.

Parameters

tree	gotowe drzewo utworzone przez funkcje create_tree()
dictionary	mapa do której mają zostać zapisane znaki oraz ich kody
prevstring	zmienna pomocnicza, do które podczas rekurencji doklejane są zera i jedynki

See also

create_tree()

Definition at line 142 of file Helpers.cpp.

4.1.1.6 create_tree()

```
WezelDrzewa create_tree (
            map< char, double > chars_with_prob )
```

Funkcja tworzy drzewo binarne. W pierwszym kroku wartości z mapy utworzonej przez calculate_probability() zamieniane są na WezelDrzewa i wkładane do wektora. Następnie wykorzustjąć węzły zawarte w wektorze zaczynamy budować drzewo. Bierzemy dwa elementy o najmniejszym prawdopodobieństwie i przypisujemy je do nowego WezelDrzewa jako jego dzieci. Następnie sortujemy wektor korzystając z compare_by_prob(). Te dwa korki powtarzamy, aż w wektorze zostanie nam jeden element, który będzie gotowym drzewem huffmana.

Parameters

chars_with_prob	mapa zawierająca znaki z prawdopodobieństwem wystąpienia w tekście

Returns

WezelDrzewa gotowe drzewo huffmana

Definition at line 168 of file Helpers.cpp.

4.1.1.7 decimal_to_binary()

```
string decimal_to_binary (
            int in )
```

Funkcja zamienia liczbę z zapisu dziesiętnego na binarny.

Parameters

in	liczba do zamiany

Returns

string zwraca liczbę zapisaną binarnie

Definition at line 70 of file Helpers.cpp.

4.1.1.8 decode_from_binary_to_text()

```
void decode_from_binary_to_text (
            map< string, char > decoDic,
            int number_of_zeros_to_remove,
            string inputname,
            string outputname )
```

Funkcja wczytuje po osiem bitów z pliku binarnego jako char. Następnie przy użyciu decimal_to_binary() chary zamieniane są na zera i jedynki i doklejone do stringa decodedmessage. W kolejnym kroku przy pomocy słownika decoDic dekodujemy zawartość decoded message i wypisujemy do pliku wyjściowego jako zdekompresowane dane.

Parameters

decoDic	słownik utworzony przez load_dic_file()
number_of_zeros_to_remove	ilość zer do usunięcia z ostatniego oktetu
inputname	nazwa zkompresowanego pliku
outputname	nazwa pliku po dekompresji

Definition at line 278 of file Helpers.cpp.

4.1.1.9 HuffmanDecode()

```
void HuffmanDecode (
            string inputname,
            string outputname,
            string dictionary )
```

Funkcja dekopresująca dane z podanego pliku. Żeby skorzystać z tej funkcji musimy podać nazwę pliku do dekompresji, oraz nazwę pliku zawierającego słownik.

Parameters

inputname	nazwa pliku do dekompresji
outputname	nazwa pliku po dekompresji
dictionary	nazwa pliku zawierająca słownik

Definition at line 327 of file Helpers.cpp.

4.1.1.10 HuffmanEncode()

```
void HuffmanEncode (
            string inputname,
            string outputname,
            string dicfile )
```

Funkcja kompresująca zawartość pliku. Tworzony jest zkompresowany plik, oraz słownik, który jest wymagany do dekompresji.

Parameters

inputname	nazwa pliku do kompresji
outputname	nazwa pliku po kompresji
dicfile	nazwa słownika

Definition at line 314 of file Helpers.cpp.

4.1.1.11 load_dic_file()

```
pair< map< string, char >, int > load_dic_file (
            string dicFile )
```

Funckja wczytuje pierwszą linijkę z pliku, w której zapisano ilość zer dodaną do ostatniego oktetu wiadmości. Następnie wczytujemy kolejne linijki zawierjące znaki(zapiasne jako int) oraz ich odpowiedniki w kodzie huffmana. Te wartości wstawiamy do mapy, która będzie użyta do odkodowania danych.

Parameters

dicFile	nazwa pliku słownika

Returns

pair<map<string, char>, int> para zawierająca gotowy słownik, oraz liczbę zer dodaną do ostatnie oktetu

Definition at line 258 of file Helpers.cpp.

4.1.1.12 output_dictionary()

```
template<typename K , typename V >
void output_dictionary (
             map< K, V > const & m,
             string dicfile,
             int zeros_added )
```

Funkcja wypisująca słownik(mapę) utworzony przez create_dictionary() do pliku.

Parameters

m	mapa z której pobieramy wartości
filename	nazwa pliku
zeros_added	ilość zer dodana do ostatniego oktetu

Definition at line 156 of file Helpers.cpp.

4.1.1.13 output_to_binary()

```
void output_to_binary (
             string huffman_coded_string,
             string outputfile )
```

Funkcja przyjmuje zakodowaną wiadomość jako string. Następnie w pętli będziemy w pętli dzielić tekst na oktety, które zostaną zapisane jako znaki wpliku wyjściowym(.bin). Do zamiany oktetu na char używamy binary_to_decimal()

Parameters

huffman_coded_string	zakodowane dane wejściowe w postaci zer i jedynek
filename	nazwa pliku, do którego będziemy zapisywać dane w postaci binarnej

Definition at line 234 of file Helpers.cpp.

4.1.1.14 setPathByFlag()

```
void setPathByFlag (
             string & flag,
             string & path,
             string & input_path,
             string & output_path,
             string & dic_path,
             string & mode )
```

Definition at line 43 of file Helpers.cpp.

4.1.1.15 split_string()

```
pair< string, char > split_string (
            string napis )
```

Funkcja dzieli podany napis na dwie części po napotkaniu znaku spacji.

Parameters

napis	wejściowy string zawierający dwie wartości oddzielone spacją

Returns

pair<string, char> zwraca dwie wartości: kod huffmana, znak ASCII zapisany jako int

Definition at line 87 of file Helpers.cpp.

4.1.1.16 validate_input_arguments()

```
int validate_input_arguments (
            int argc,
            vector< string > & arg )
```

Definition at line 16 of file Helpers.cpp.

4.1.2 Variable Documentation

4.1.2.1 dictionary

```
map<char, string> dictionary
```

Definition at line 13 of file Helpers.cpp.

4.2 Helpers.cpp

Go to the documentation of this file.

```
00001 #include "Helpers.h"
00002 #include <iostream>
00003 #include <vector>
00004 #include <map>
00005 #include <utility>
00006 #include <fstream>
00007 #include <bitset>
00008 #include <cstdlib>
00009 #include <string>
00010 #include <algorithm>
00011 using namespace std;
00012
00013 map<char, string> dictionary;
00014
00015
00016 int validate_input_arguments(int argc, vector<string> &arg) {
00017     if (argc == 1 || arg[1] == "-h" || arg[1] == "--help") {
00018         cout « "User manual\n"
00019                 "Usage:\n"
00020                 "   -i(--input) input_filename \n"
00021                 "   -o(--output) output_filename\n"
00022                 "   -s(--slownik) slownik_filename \n"
00023                 "   -t(--tryb) k - kompresja, d - dekompresja \n"
00024                 "All four arguments are necessary to run program. For compression output file type
       should be .bin and for decompresion input should be .bin\n";
00025         return -1;
00026     }
00027     if (argc > 1 && argc != 9) {
00028         cout « argc;
00029         cout « "The number of arguments is not equal 4. Type '-h' and check manual\n";
00030         return -1;
00031     }
00032     if (arg[1] == arg[3]) {
00033         cout « "Can't use the same flag two times. Type '-h' and check manual\n";
00034         return -1;
00035     }
00036     if (arg[2] == arg[4]) {
00037         cout « "Can't use the same file for input and output. Type '-h' and check manual\n";
00038         return -1;
00039     }
00040     return 0;
00041 }
00042
00043 void setPathByFlag(string& flag, string& path, string& input_path, string& output_path, string&
       dic_path, string& mode) {
00044     if (flag == "-i" || flag == "--input") {
00045         input_path = path;
00046     }
00047     else if (flag == "-o" || flag == "--output") {
00048         output_path = path;
00049     }
00050     else if (flag == "-s" || flag == "--slownik") {
00051         dic_path = path;
00052     }
00053     else if (flag == "-t" || flag == "--tryb") {
00054         mode = path;
00055     }
00056     else {
00057         cout « "Unknown flag. Type '-h' and check manual\n";
00058     }
00059 }
00060
00061
00062 int binary_to_decimal(string& in)
00063 {
00064     int result = 0;
00065     for (int i = 0; i < (int)in.size(); i++)
00066         result = result * 2 + in[i] - '0';
00067     return result;
00068 }
00069
00070 string decimal_to_binary(int in)
00071 {
00072     string temp = "";
00073     string result = "";
00074     while (in)
00075     {
00076         temp += ('0' + in % 2);
00077         in /= 2;
00078     }
00079     result.append(8 - temp.size(), '0');
00080     for (int i = temp.size() - 1; i >= 0; i--)
```

```
00081     {
00082         result += temp[i];
00083     }
00084     return result;
00085 }
00086
00087 pair<string, char> split_string(string napis)
00088 {
00089     pair<string, char> wynik;
00090     string znak = "";
00091     string kod = "";
00092     bool space = false;
00093     for (int i = 0; i < (int)napis.length(); i++)
00094     {
00095         if (napis[i] == ' ')
00096         {
00097             space = true;
00098             continue;
00099         }
00100         if (!space)
00101         {
00102             znak += napis[i];
00103         }
00104         else
00105         {
00106             kod += napis[i];
00107         }
00108     }
00109     wynik.second = char(stoi(znak));
00110     wynik.first = kod;
00111     return wynik;
00112 }
00113
00114 bool compare_by_prob(const WezelDrzewa& a, const WezelDrzewa& b)
00115 {
00116     return a.probability > b.probability;
00117 }
00118
00119 map<char, double> calculate_probability(string inputname)
00120 {
00121     int number_of_characters = 0;
00122     string line;
00123     map<char, double> dane;
00124     ifstream infile(inputname);
00125     while (getline(infile, line))
00126     {
00127         number_of_characters += line.length();
00128         for (int i = 0; i < (int)line.length(); i++)
00129         {
00130             dane[line[i]]++;
00131         }
00132         dane['\n']++;
00133     }
00134     infile.close();
00135     for (auto& it : dane)
00136     {
00137         dane[it.first] = it.second / number_of_characters;
00138     }
00139     return dane;
00140 }
00141
00142 void create_dictionary(WezelDrzewa* tree, map<char, string>& dictionary, string prevstring)
00143 {
00144     if (tree)
00145     {
00146         if (int(tree->ch[0]) != 0)
00147         {
00148             dictionary.insert(std::pair<char, string>(char(tree->ch[0]), prevstring));
00149         }
00150         create_dictionary(tree->left, dictionary, prevstring + "0");
00151         create_dictionary(tree->right, dictionary, prevstring + "1");
00152     }
00153 }
00154
00155 template <typename K, typename V>
00156 void output_dictionary(map<K, V> const& m, string dicfile, int zeros_added)
00157 {
00158     ofstream plik;
00159     plik.open(dicfile);
00160     plik « zeros_added « '\n';
00161     for (auto const& pair : m)
00162     {
00163         plik « int(pair.first) « " " « pair.second « '\n';
00164     }
00165     plik.close();
00166 }
00167
```

```
00168 WezelDrzewa create_tree(map<char, double> chars_with_prob)
00169 {
00170     vector<WezelDrzewa> elementyDoUtworzeniaDrzewa;
00171     for (auto const& pair : chars_with_prob)
00172     {
00173         WezelDrzewa x;
00174         x.left = NULL;
00175         x.right = NULL;
00176         x.ch = pair.first;
00177         x.probability = pair.second;
00178         elementyDoUtworzeniaDrzewa.push_back(x);
00179     }
00180     //Create tree from nodes
00181     while (elementyDoUtworzeniaDrzewa.size() > 1)
00182     {
00183         WezelDrzewa* node1 = new WezelDrzewa(elementyDoUtworzeniaDrzewa.back());
00184         elementyDoUtworzeniaDrzewa.pop_back();
00185         WezelDrzewa* node2 = new WezelDrzewa(elementyDoUtworzeniaDrzewa.back());
00186         elementyDoUtworzeniaDrzewa.pop_back();
00187
00188         WezelDrzewa x;
00189         x.ch = "";
00190         x.probability = node1->probability + node2->probability;
00191         if (node1->probability < node2->probability)
00192         {
00193             x.left = node1;
00194             x.right = node2;
00195         }
00196         else
00197         {
00198             x.left = node2;
00199             x.right = node1;
00200         }
00201         elementyDoUtworzeniaDrzewa.push_back(x);
00202         sort(elementyDoUtworzeniaDrzewa.begin(), elementyDoUtworzeniaDrzewa.end(), compare_by_prob);
00203     }
00204     return elementyDoUtworzeniaDrzewa.back();
00205 }
00206
00207 pair<string, int> coded_message(map<char, string> dictionary, string inputfile)
00208 {
00209     string huffman_coded_string = "";
00210     ifstream file(inputfile);
00211     string line;
00212     while (getline(file, line))
00213     {
00214         for (int i = 0; i < (int)line.length(); i++)
00215         {
00216             huffman_coded_string += dictionary[line[i]];
00217         }
00218         huffman_coded_string += dictionary['\n'];
00219     }
00220     file.close();
00221
00222     int number_added_zeros = 8 - huffman_coded_string.length() % 8;
00223     if (number_added_zeros != 0)
00224     {
00225         for (int i = 0; i < number_added_zeros; i++)
00226         {
00227             huffman_coded_string += "0";
00228         }
00229     }
00230     pair<string, int> result(huffman_coded_string, number_added_zeros);
00231     return result;
00232 }
00233
00234 void output_to_binary(string huffman_coded_string, string outputfile)
00235 {
00236     string in = "";
00237     string part_of_string = "";
00238     ofstream compressed(outputfile, ios::binary);
00239     for (int i = 1; i <= (int)huffman_coded_string.length(); i++)
00240     {
00241         if (part_of_string.length() == 7)
00242         {
00243             part_of_string += huffman_coded_string[i - 1];
00244             in += (char)binary_to_decimal(part_of_string);
00245             part_of_string = "";
00246         }
00247         else
00248         {
00249             part_of_string += huffman_coded_string[i - 1];
00250         }
00251     }
00252     compressed.write(in.c_str(), in.size());
00253     compressed.close();
00254 }
```

```
00255
00256
00257 // Decoding
00258 pair<map<string, char>, int> load_dic_file(string dicFile)
00259 {
00260     map<string, char> decoDic;
00261     string line, number = "";
00262
00263     ifstream dict(dicFile);
00264     getline(dict, line);
00265     number.push_back(line[0]);
00266
00267     int number_of_zeros_to_remove = stoi(number);
00268
00269     while (getline(dict, line))
00270     {
00271         decoDic.insert(pair<string, char>(split_string(line).first, split_string(line).second));
00272     }
00273     dict.close();
00274     pair<map<string, char>, int> res(decoDic, number_of_zeros_to_remove);
00275     return res;
00276 }
00277
00278 void decode_from_binary_to_text(map<string, char> decoDic, int number_of_zeros_to_remove, string
      inputname, string outputname)
00279 {
00280
00281     ifstream codedmessage(inputname, ifstream::in | ios::binary);
00282     string decodedmessage = "";
00283     vector<unsigned char> text;
00284     unsigned char textseg;
00285     codedmessage.read(reinterpret_cast<char*>(&textseg), 1);
00286     while (!codedmessage.eof())
00287     {
00288         text.push_back(textseg);
00289         codedmessage.read(reinterpret_cast<char*>(&textseg), 1);
00290     }
00291     codedmessage.close();
00292     for (int i = 0; i < (int)text.size(); i++)
00293     {
00294         decodedmessage += decimal_to_binary(text[i]);
00295     }
00296
00297     ofstream decoded_message_file(outputname);
00298     string ciag = "";
00299     map<string, char>::iterator it;
00300     for (int i = 0; i < (int)decodedmessage.length() - number_of_zeros_to_remove; i++)
00301     {
00302         ciag += decodedmessage[i];
00303         it = decoDic.find(ciag);
00304         if (it != decoDic.end())
00305         {
00306             decoded_message_file << it->second;
00307             ciag = "";
00308         }
00309     }
00310     decoded_message_file.close();
00311
00312 }
00313
00314 void HuffmanEncode(string inputname, string outputname, string dicfile)
00315 {
00316     map<char, double> chars_with_prob = calculate_probability(inputname);
00317     WezelDrzewa* prepared_tree = new WezelDrzewa(create_tree(chars_with_prob));
00318     map<char, string> dictionary;
00319
00320     create_dictionary(prepared_tree, dictionary, "");
00321     pair<string, int> data_for_output = coded_message(dictionary, inputname);
00322
00323     output_to_binary(data_for_output.first, outputname);
00324     output_dictionary(dictionary, dicfile, data_for_output.second);
00325 }
00326
00327 void HuffmanDecode(string inputname, string outputname, string dictionary)
00328 {
00329     pair<map<string, char>, int> dictionary_data = load_dic_file(dictionary);
00330     decode_from_binary_to_text(dictionary_data.first, dictionary_data.second, inputname ,outputname);
00331 }
```

4.3 Helpers.h File Reference

```
#include <iostream>
#include <vector>
#include <map>
#include <utility>
#include <fstream>
#include <bitset>
#include <cstdlib>
#include <string>
```

Classes

- struct WezelDrzewa

  Struktura używana przy tworzeniu drzewa, przechowuje znak oraz prawdopodobieństwo jego wystąpienia w tekście.

Functions

- int validate_input_arguments (int argc, vector< string > &arg)
- void setPathByFlag (string &flag, string &path, string &input_path, string &output_path, string &dic_path, string &mode)
- int binary_to_decimal (string &in)
- string decimal_to_binary (int in)
- pair< string, char > split_string (string napis)
- bool compare_by_prob (const WezelDrzewa &a, const WezelDrzewa &b)
- map< char, double > calculate_probability (string inputname)
- void create_dictionary (WezelDrzewa *tree, map< char, string > &dictionary, string prevstring)
- template<typename K , typename V >
  void output_dictionary (map< K, V > const &m, string dicfile, int zeros_added)
- WezelDrzewa create_tree (map< char, double > chars_with_prob)
- pair< string, int > coded_message (map< char, string > dictionary, string inputfile)
- void output_to_binary (string huffman_coded_string, string outputfile)
- pair< map< string, char >, int > load_dic_file (string dicFile)
- void decode_from_binary_to_text (map< string, char > decoDic, int number_of_zeros_to_remove, string inputname, string outputname)
- void HuffmanEncode (string inputname, string outputname, string dicfile)
- void HuffmanDecode (string inputname, string outputname, string dictionary)

4.3.1 Function Documentation

4.3.1.1 binary_to_decimal()

```
int binary_to_decimal (
            string & in )
```

Funkcja przyjmuje oktet, który zamienia z wartości binarnej na wartość dziesiętną.

Parameters

in	8 bitów zapisane jako string

Returns

int

Definition at line 62 of file Helpers.cpp.

4.3.1.2 calculate_probability()

```
map< char, double > calculate_probability (
            string inputname )
```

Funkcja zapisuje wystąpienia znaków do mapy, aby na końcu podzielić ilość wystąpień znaku przez ilość wszystkich znaków w tekście. Otrzymujemy w ten sposób prawdopodobieństwo wystąpienia znaku.

Parameters

filename	nazwa pliku, z którego chcemy wczytać dane

Returns

map<char, double> mapa zawierająca znaki z prawdopodobieństwem ich wysąpienia

Definition at line 119 of file Helpers.cpp.

4.3.1.3 coded_message()

```
pair< string, int > coded_message (
            map< char, string > dictionary,
            string inputfile )
```

Funkcja koduje dane z pliku wejściowego używając słownika stworzonego przez create_dictionary(). Po zakodowaniu wszystkich znaków sprawdza czy ilość zer i jedynek jest podzielna przez 8. Jeżeli nie to doklejamy odpowiednią ilość zer na koniec kodu.

Parameters

dictionary	słownik utworzony przez create_dictionary()
filename	nazwa pliku

Returns

pair<string, int> para zawierająca zakodowany tekst oraz ilość zer dodanych do ostatniego oktetu

Definition at line 207 of file Helpers.cpp.

4.3.1.4 compare_by_prob()

```
bool compare_by_prob (
            const WezelDrzewa & a,
            const WezelDrzewa & b )
```

Funkcja pomagająca przy sortoaniu węzłów drzewa znajdujących się w wektorze porównując prawdopodobieństwo.

Parameters

a	pierwsz węzeł drzewa
b	drgi węzeł drzewa

Returns

true zwraca prawdę jeżeli prawdopodobieństwo zawarte w węźle a jest większe

false

See also

WezelDrzewa

Definition at line 114 of file Helpers.cpp.

4.3.1.5 create_dictionary()

```
void create_dictionary (
            WezelDrzewa * tree,
            map< char, string > & dictionary,
            string prevstring )
```

Struktura WezelDrzewa jest używana do tworzenia drzewa binarnego. WezelDrzewa oprócz standardowych wartości, zawiera również wartość ch oraz probability, które kolejno oznaczają znak, oraz jego prawdopodobieństwo wystąpienia w tekście. Funkcja reukrencyjnie przechodzi po drzewie tworząc kody huffmana dla poszczególnych znaków. Gdy nie ma możliwości przejścia do kolejnych potomków, utworzony kod(w zapisie binarnym) zostaje dodany jako element mapy, wraz ze znakiem, dla którego kod utworzono.

Parameters

tree	gotowe drzewo utworzone przez funkcje create_tree()
dictionary	mapa do której mają zostać zapisane znaki oraz ich kody
prevstring	zmienna pomocnicza, do które podczas rekurencji doklejane są zera i jedynki

See also

create_tree()

Definition at line 142 of file Helpers.cpp.

4.3.1.6 create_tree()

```
WezelDrzewa create_tree (
            map< char, double > chars_with_prob )
```

Funkcja tworzy drzewo binarne. W pierwszym kroku wartości z mapy utworzonej przez calculate_probability() zamieniane są na WezelDrzewa i wkładane do wektora. Następnie wykorzustjąć węzły zawarte w wektorze zaczynamy budować drzewo. Bierzemy dwa elementy o najmniejszym prawdopodobieństwie i przypisujemy je do nowego WezelDrzewa jako jego dzieci. Następnie sortujemy wektor korzystając z compare_by_prob(). Te dwa korki powtarzamy, aż w wektorze zostanie nam jeden element, który będzie gotowym drzewem huffmana.

Parameters

chars_with_prob	mapa zawierająca znaki z prawdopodobieństwem wystąpienia w tekście

Returns

WezelDrzewa gotowe drzewo huffmana

Definition at line 168 of file Helpers.cpp.

4.3.1.7 decimal_to_binary()

```
string decimal_to_binary (
            int in )
```

Funkcja zamienia liczbę z zapisu dziesiętnego na binarny.

Parameters

in	liczba do zamiany

Returns

string zwraca liczbę zapisaną binarnie

Definition at line 70 of file Helpers.cpp.

4.3.1.8 decode_from_binary_to_text()

```
void decode_from_binary_to_text (
            map< string, char > decoDic,
            int number_of_zeros_to_remove,
            string inputname,
            string outputname )
```

Funkcja wczytuje po osiem bitów z pliku binarnego jako char. Następnie przy użyciu decimal_to_binary() chary zamieniane są na zera i jedynki i doklejone do stringa decodedmessage. W kolejnym kroku przy pomocy słownika decoDic dekodujemy zawartość decoded message i wypisujemy do pliku wyjściowego jako zdekompresowane dane.

Parameters

decoDic	słownik utworzony przez load_dic_file()
number_of_zeros_to_remove	ilość zer do usunięcia z ostatniego oktetu
inputname	nazwa zkompresowanego pliku
outputname	nazwa pliku po dekompresji

Definition at line 278 of file Helpers.cpp.

4.3.1.9 HuffmanDecode()

```
void HuffmanDecode (
            string inputname,
            string outputname,
            string dictionary )
```

Funkcja dekopresująca dane z podanego pliku. Żeby skorzystać z tej funkcji musimy podać nazwę pliku do dekompresji, oraz nazwę pliku zawierającego słownik.

Parameters

inputname	nazwa pliku do dekompresji
outputname	nazwa pliku po dekompresji
dictionary	nazwa pliku zawierająca słownik

Definition at line 327 of file Helpers.cpp.

4.3.1.10 HuffmanEncode()

```
void HuffmanEncode (
            string inputname,
            string outputname,
            string dicfile )
```

Funkcja kompresująca zawartość pliku. Tworzony jest zkompresowany plik, oraz słownik, który jest wymagany do dekompresji.

Parameters

inputname	nazwa pliku do kompresji
outputname	nazwa pliku po kompresji
dicfile	nazwa słownika

Definition at line 314 of file Helpers.cpp.

4.3.1.11 load_dic_file()

```
pair< map< string, char >, int > load_dic_file (
            string dicFile )
```

Funckja wczytuje pierwszą linijkę z pliku, w której zapisano ilość zer dodaną do ostatniego oktetu wiadmości. Następnie wczytujemy kolejne linijki zawierające znaki(zapiasne jako int) oraz ich odpowiedniki w kodzie huffmana. Te wartości wstawiamy do mapy, która będzie użyta do odkodowania danych.

Parameters

dicFile	nazwa pliku słownika

Returns

pair<map<string, char>, int> para zawierająca gotowy słownik, oraz liczbę zer dodaną do ostatnie oktetu

Definition at line 258 of file Helpers.cpp.

4.3.1.12 output_dictionary()

```
template<typename K , typename V >
void output_dictionary (
            map< K, V > const & m,
            string dicfile,
            int zeros_added )
```

Funkcja wypisująca słownik(mapę) utworzony przez create_dictionary() do pliku.

Parameters

m	mapa z której pobieramy wartości
filename	nazwa pliku
zeros_added	ilość zer dodana do ostatniego oktetu

Definition at line 156 of file Helpers.cpp.

4.3.1.13 output_to_binary()

```
void output_to_binary (
            string huffman_coded_string,
            string outputfile )
```

Funkcja przyjmuje zakodowaną wiadomość jako string. Następnie w pętli będziemy w pętli dzielić tekst na oktety, które zostaną zapisane jako znaki wpliku wyjściowym(.bin). Do zamiany oktetu na char używamy binary_to_decimal()

Parameters

huffman_coded_string	zakodowane dane wejściowe w postaci zer i jedynek
filename	nazwa pliku, do którego będziemy zapisywać dane w postaci binarnej

Definition at line 234 of file Helpers.cpp.

4.3.1.14 setPathByFlag()

```
void setPathByFlag (
            string & flag,
            string & path,
            string & input_path,
            string & output_path,
            string & dic_path,
            string & mode )
```

Definition at line 43 of file Helpers.cpp.

4.3.1.15 split_string()

```
pair< string, char > split_string (
            string napis )
```

Funkcja dzieli podany napis na dwie części po napotkaniu znaku spacji.

Parameters

napis	wejściowy string zawierający dwie wartości oddzielone spacją

Returns

pair<string, char> zwraca dwie wartości: kod huffmana, znak ASCII zapisany jako int

Definition at line 87 of file Helpers.cpp.

4.3.1.16 validate_input_arguments()

```
int validate_input_arguments (
            int argc,
            vector< string > & arg )
```

Definition at line 16 of file Helpers.cpp.

4.4 Helpers.h

Go to the documentation of this file.

```
00001 #ifndef  HELPERS_H
00002 #define HELPERS_H
00003 #endif // ! HELPERS_H
00004
00005 #include <iostream>
00006 #include <vector>
00007 #include <map>
00008 #include <utility>
00009 #include <fstream>
00010 #include <bitset>
00011 #include <cstdlib>
00012 #include <string>
00013 using namespace std;
00014
00015 int validate_input_arguments(int argc, vector<string> &arg);
00016
00017 void setPathByFlag(string& flag, string& path, string& input_path, string& output_path, string&
       dic_path, string& mode);
00018
00023 struct WezelDrzewa
00024 {
00029     struct WezelDrzewa* parent = NULL;
00034     struct WezelDrzewa * left = NULL;
00039     struct WezelDrzewa * right = NULL;
00044     string ch;
00045     double probability = NULL;
00046 };
00047
00054 int binary_to_decimal(string& in);
00055
00062 string decimal_to_binary(int in);
00069 pair<string, char> split_string(string napis);
00079 bool compare_by_prob(const WezelDrzewa& a, const WezelDrzewa& b);
00086 map<char, double> calculate_probability(string inputname);
00087
00102 void create_dictionary(WezelDrzewa* tree, map<char, string>& dictionary, string prevstring);
00110 template <typename K, typename V>
00111 void output_dictionary(map<K, V> const& m, string dicfile, int zeros_added);
00118 WezelDrzewa create_tree(map<char, double> chars_with_prob);
00126 pair<string, int> coded_message(map<char, string> dictionary, string inputfile);
00133 void output_to_binary(string huffman_coded_string, string outputfile);
00140 pair<map<string, char>, int> load_dic_file(string dicFile);
00149 void decode_from_binary_to_text(map<string, char> decoDic, int number_of_zeros_to_remove, string
       inputname, string outputname);
00150
00158 void HuffmanEncode(string inputname, string outputname, string dicfile);
00166 void HuffmanDecode(string inputname, string outputname, string dictionary);
```

4.5 huffman-coding.cpp File Reference

```
#include "Helpers.h"
#include <iostream>
```

Functions

- int main (int argc, char **argv)

4.5.1 Function Documentation

4.5.1.1 main()

```
int main (
            int argc,
            char ** argv )
```

Definition at line 5 of file huffman-coding.cpp.

4.6 huffman-coding.cpp

Go to the documentation of this file.

```
00001 #include "Helpers.h"
00002 #include <iostream>
00003 using namespace std;
00004
00005 int main(int argc, char** argv)
00006 {
00007     string input_path, output_path, dic_path, mode;
00008     vector<string> arg(argv, argv + argc);
00009
00010
00011     if (validate_input_arguments(argc, arg) == -1) {
00012         return 0;
00013     }
00014
00015     setPathByFlag(arg[1], arg[2], input_path, output_path, dic_path, mode);
00016     setPathByFlag(arg[3], arg[4], input_path, output_path, dic_path, mode);
00017     setPathByFlag(arg[5], arg[6], input_path, output_path, dic_path, mode);
00018     setPathByFlag(arg[7], arg[8], input_path, output_path, dic_path, mode);
00019
00020
00021     if (mode == "k")
00022     {
00023         HuffmanEncode(input_path, output_path, dic_path);
00024     }
00025     else if(mode == "d")
00026     {
00027         HuffmanDecode(input_path, output_path, dic_path);
00028     }
00029     else
00030     {
00031         cout « "================================================================================"«
      endl;
00032         cout « "Use correct format" « endl;
00033         cout « "For compressing data use:"«endl;
00034         cout « "huffman-coding -i input_filename -o output_filename -s dictionary_filename -t k"«endl;
00035         cout « "For decompressing data use:"«endl;
00036         cout « "huffman-coding -i input_filename -o output_filename -s dictionary_filename -t d"«endl;
00037         cout « "================================================================================" «
      endl;
00038     }
00039     return 1;
00040 }
```